Eduardo Diedrich

Senior Data Engineer · Especialista en Analítica Avanzada

Python · Spark y Databricks · AWS y Azure · Snowflake

Salta, Argentina (GMT-3) | +54 9 387 222-2879 | eduardo.diedrich@outlook.com.ar

Perfil

Ingeniero de datos con más de 15 años en sistemas de datos: **6+ años de Python en producción** (PySpark, pandas, scikit-learn), **4+ años de Spark** en tres entornos de ejecución (AWS Glue, Azure Databricks, Synapse) y **3+ años sobre Databricks** (Delta Lake, orquestación de jobs, ajuste de clusters). Experiencia completa en el stack de datos de AWS (S3, Glue, Redshift, Lambda) y en **Snowflake** (warehousing y ELT). Resultados: **99,9 % de exactitud de datos**, **40 % de mejora en rendimiento de pipelines**, **80 % de mejora en el ciclo de decisión de marketing**. Investigador con publicaciones en clustering a gran escala, psicometría y métodos formales.

Dominio técnico *(uso práctico, en producción)*

- **Python — 6+ años (2019–hoy):** transformaciones PySpark, pandas/NumPy, scikit-learn, ETL orquestado con Airflow, automatización de pruebas.
- **Databricks — 3+ años (2021–hoy):** notebooks y jobs Spark/PySpark, tablas Delta Lake, arquitectura medallion, dimensionamiento y costo de clusters.
- **SQL / T-SQL / SparkSQL — 15 años:** optimización de consultas, procedimientos almacenados, CDC, cargas analíticas de varios TB.
- **Procesamiento distribuido — 4+ años:** particionado, ajuste de shuffles y joins, optimización de costo y tiempo en Glue, Databricks y Synapse.
- **Azure — 4+ años:** ADF, ADLS, Synapse, Databricks, CI/CD de pipelines. **AWS:** S3, Glue, Redshift, Lambda, RDS, DynamoDB, CloudWatch.
- **Snowflake — 4 años:** warehousing, ELT, SnowSQL, Streams & Tasks, Data Sharing (SnowPro Core en curso).
- **Geoespacial y documental:** geopandas, rasterio, pyproj; OCR con Tesseract y procesamiento paralelo reanudable.

Experiencia profesional

InterEx Inc. — cliente Marvell Technology | Senior Data Engineer *jun 2026 – ago 2026 · remoto*

- Calidad de datos de RR. HH. y dotación (headcount) sobre el lakehouse en **Databricks**.
- Relevamiento del linaje hacia la capa **bronze**: detecté una ingesta que dependía de un script de Python local que generaba un Excel fuera de Databricks, y propuse llevarla al pipeline gobernado.

EPAM Systems | Senior Data Engineer *ago 2025 – feb 2026*

- Iniciativas de ingeniería de datos para clientes corporativos sobre lakehouses en **Databricks**.
- Desarrollo y revisión de pipelines **PySpark** con patrones Delta Lake para cargas incrementales e idempotentes.

Perficient | Data Engineer y Analytics Specialist *sep 2024 – mar 2025*

- Integración de datos en **Azure Databricks** para migraciones de DB2 a la nube, con pipelines Spark/PySpark.
- Marcos de gobierno de datos con 99,9 % de exactitud en producción; soluciones de warehousing en Snowflake.

JMFamily | Senior Data Engineer *nov 2023 – dic 2024*

- Migración Oracle RDS → SQL Server en **PySpark sobre Databricks**, orquestada con ADF.
- Refactorización de SparkSQL y Python: **40 % menos de tiempo de ejecución**. CI/CD y tableros ejecutivos.

Teladoc Health | Healthcare Data Engineer *abr 2023 – abr 2024*

- **99,9 % de exactitud** en procesamiento de datos de salud con Talend y Python; validación y monitoreo para cumplimiento regulatorio.

Globant | Data Engineer y Analytics Consultant *nov 2021 – abr 2023*

- Soluciones con **Databricks, PySpark y ADF** para clientes financieros, automotrices y de retail.
- Stack de datos de AWS de punta a punta para el cliente automotriz: jobs **Glue (PySpark)** sobre zonas S3, modelado en **Redshift** y **Lambda** para ingesta por eventos.
- Data warehouses en **Snowflake** (clustering, particionado, tuning) y ELT con SnowSQL, Streams y Tasks; Data Sharing entre organizaciones.

Insyte | Cloud Data Engineer *jun 2022 – dic 2022*

- ETL en **AWS Glue (PySpark)** procesando terabytes diarios; RDS, DynamoDB, S3 y monitoreo con CloudWatch.

TyE | Especialista en Migración de Datos y BI *mar 2010 – dic 2020*

- Migraciones sin pérdida de datos en más de 30 módulos para más de 5.000 usuarios; T-SQL **50 % más eficiente**; analítica POS y CDC.

Proyectos e investigación *(detalle en el portfolio adjunto)*

- **Pipeline de extracción documental (2026):** OCR paralelo y reanudable sobre boletines oficiales 1908–1955, búsqueda difusa en cuatro pasadas, hashing perceptual y salidas CSV cruzables.
- **Pipeline geoespacial reproducible (2026):** capas del IGN, Censo 2022 (INDEC) y modelo digital de elevación de 30 m, con geopandas y rasterio.
- **Segmentación a escala (2025):** 1.000.000 de registros con PCA y MiniBatch K-Means en 57,9 s.
- **Psicometría (2024):** modelos de Rasch y clases latentes sobre 310 protocolos del 911 de Salta; instrumento reducido de 12 a 6 ítems.
- **UCASAL, Marketing (2016–2020):** pronóstico de inscripciones, segmentación K-means/PCA, +35 % de retención y tableros de BI.
- **App web «Libro de la huerta» (2026):** registro productivo con agregados por especie y mes y exportación a Excel.

Formación y certificaciones

Universidad Nacional de Salta — Licenciatura en Análisis de Sistemas 2009
Universidad Nacional de Salta — Computador Universitario (título intermedio) 2000
Promidat (Costa Rica) — Programa Experto en Ciencia de Datos (Python/R), diploma y 10 módulos 2019
Snowflake — SnowPro Core (en curso)

Idiomas y otros

Idiomas: español (nativo), inglés (profesional avanzado). **Metodologías:** Agile/Scrum, investigación estadística, métodos formales. **Documentación técnica:** LaTeX con figuras y tablas generadas desde Python.