Portfolio

Ingeniería de datos y analítica avanzada

Eduardo Diedrich
Senior Data Engineer · Licenciado en Análisis de Sistemas (UNSa)
Salta, Argentina · +54 9 387 222-2879 · eduardo.diedrich@outlook.com.ar

N.º	Proyecto	Stack principal
1	Pipeline de extracción documental con OCR	Python, Tesseract, multiprocessing
2	Pipeline geoespacial reproducible	geopandas, rasterio, pyproj
3	Segmentación de 1.000.000 de registros	scikit-learn, PCA, MiniBatch K-Means
4	Perfiles de interés educativo (UCASAL)	clustering, árboles de decisión
5	Psicometría con variables latentes	R, Rasch, clases latentes
6	App web «Libro de la huerta»	HTML/JS, almacenamiento compartido, Excel
7	Investigación en teoría de números	Python, Coq, LaTeX
8	Formación y certificaciones	—

La experiencia laboral en empresas (EPAM, Perficient, JMFamily, Teladoc, Globant, Insyte, InterEx/Marvell) se detalla en el CV. Este portfolio reúne trabajo propio que se puede mostrar sin afectar la confidencialidad de clientes. Todos los documentos fueron escritos en LaTeX y las figuras se generan desde Python.

1 Pipeline de extracción documental con OCR

Problema: buscar menciones de un territorio en casi cincuenta años de boletines oficiales provinciales (1908–1955), escaneados con calidad dispar, algunos con capa de texto y otros sin ella. **Rol:** diseño y desarrollo completo. **Stack:** Python 3.12, Tesseract (spa), `concurrent.futures`, difflib, hashing perceptual, Git con Releases para los datos pesados.

Qué hace el pipeline (≈1.200 líneas, pensado para correr días enteros sin supervisión):

- **Ingesta e inventario:** detecta si cada edición es un PDF real o un ZIP disfrazado, aprovecha la capa de texto si existe y cuenta marcas de corte.
- **OCR propio en paralelo** sobre todas las hojas, **reanudable**, con **escritura atómica** y confianza por hoja (salida TXT + TSV).
- **Validación de metadatos:** número, fecha y día de la semana de cada edición; páginas declaradas contra páginas presentes; días hábiles sin edición.
- **Búsqueda en cuatro pasadas** (literal, normalizada, laxa y difusa) sobre la unión de versiones de texto, con anillos de términos y de actores configurables por JSON.
- **Deduplicación de imágenes** con md5 y dHash perceptual.
- **Salidas:** pre-informe por año, CSV de resultados y recortes de imagen de cada hallazgo para revisión humana.

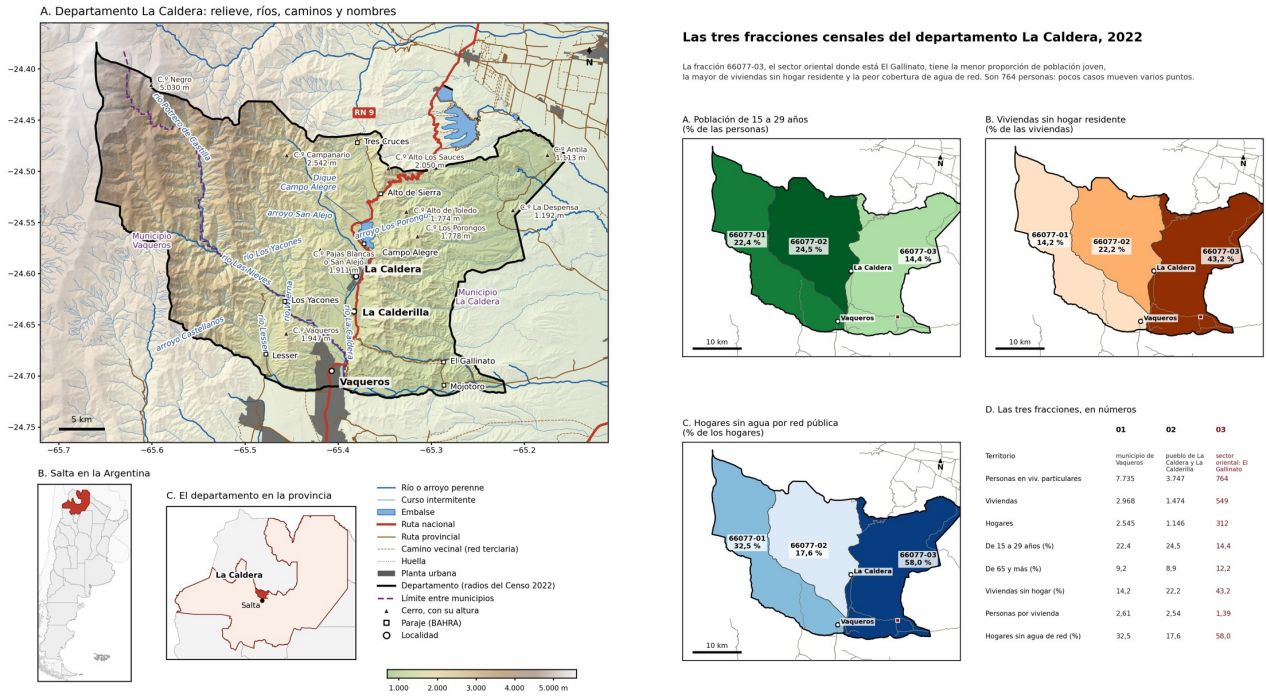
Calidad de datos como proceso. El pipeline se rige por una rúbrica versionada (16 versiones). Cada versión nace de defectos reales encontrados en las salidas. Por ejemplo, listas transcriptas que no se recontaban, marcadores de sección inestables que impedían cruzar años con un script, una configuración desactualizada que el proceso no detectaba, o un control muestral informado como si fuera completo. Cada defecto generó una regla y un control automático (`control_config.py`).

Resultado: los 48 años procesados (1908–1955), con informes anuales cruzables entre sí y trazabilidad de cada hallazgo hasta la imagen original.

2 Pipeline geoespacial reproducible

Problema: producir cartografía temática de un departamento de Salta, lista para imprenta, integrando fuentes oficiales heterogéneas. **Stack:** geopandas, pyogrio, rasterio, shapely, pyproj, matplotlib, adjustText. **Tamaño:** 21 scripts, ≈2.100 líneas.

- **Fuentes:** capas del IGN (límites, hidrografía, red vial, hábitat), radios del Censo 2022 (INDEC, cartografía corregida CEUR-CONICET), catastro parcelario (IDESA), BAHRA y el modelo digital de elevación MDE-Ar v2.1 de 30 m (cuatro hojas en mosaico).
- **Normalización:** todo en EPSG:4326; las superficies se calculan en una proyección equivalente (EPSG:6933). Las capas nacionales se recortan a la caja del área de estudio con un script de incorporación (`incorporar.py`).
- **Reproducibilidad:** `requirements.txt` probado, descarga automática de capas pesadas desde los Releases (con normalización de rutas de Windows), un módulo de estilo común (escala, norte, contorno) y figuras a 300 dpi generadas por script.
- **Analítica censal:** indicadores por fracción y radio (estructura etaria, viviendas sin hogar residente, acceso a agua de red) procesados desde Redatam.



Izquierda: relieve, hidrografía, red vial y toponimia. Derecha: indicadores del Censo 2022 por fracción censal.

3 Segmentación de 1.000.000 de registros

Datos: 1.000.000 de registros delictivos públicos (99,5 % del conjunto), 34 variables con codificación cíclica de hora y fecha. **Stack:** Python, scikit-learn (RobustScaler, PCA, MiniBatch K-Means). **Muestra:** `03_Muestras/Segmentacion_1M_registros.pdf`.

- Pipeline optimizado de punta a punta en **57,9 segundos**: PCA a 4 dimensiones (44,5 % de varianza) y MiniBatch K-Means con lotes de 2.000.
- Cuatro perfiles demográficos estables (silueta 0,256), con interpretación de cada componente: perfil de la víctima, tipo de interacción, naturaleza del delito y contexto espacio-temporal.
- Versión anterior sobre 166.872 registros con 99,8 % de pureza de perfiles.

4 Perfiles de interés en la oferta educativa (UCASAL)

Contexto: proyecto final del Programa Experto en Minería de Datos (Promidat) sobre datos de marketing de la Universidad Católica de Salta. **Muestra:** `03_Muestras/Clustering_y_arbol_UCASAL.pdf`.

- Clustering jerárquico con índice de no-borrosidad (0,617): 76 % «adultos a distancia» frente a 24 % «estudiantes jóvenes».
- Árboles de decisión para predecir la pertenencia a cada perfil y orientar campañas: entre 15 y 20 % de mejora en conversión.
- Durante 2016–2020, en la misma área: pronóstico de inscripciones, +35 % de retención y tableros de BI.

5 Psicometría con variables latentes

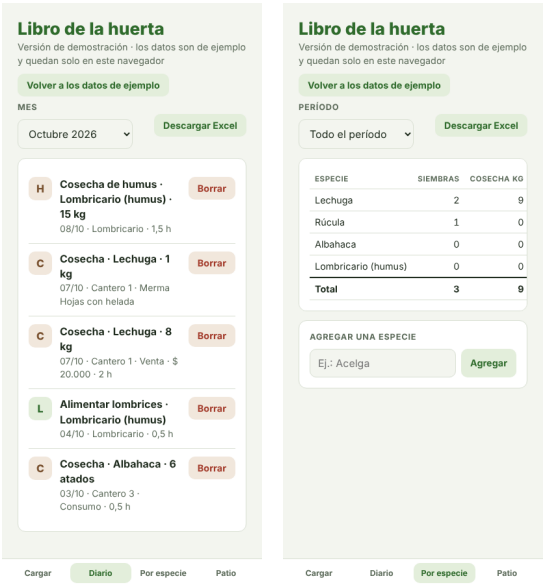
Contexto: Consejo de Investigación, Facultad de Artes y Ciencias, Universidad Católica de Salta (2024). Datos del Servicio de Psicología del Sistema de Emergencias 911 de Salta. **Muestras:** artículo y presentación en `03_Muestras/`.

- Modelo de Rasch y Rasch mixto sobre 310 protocolos: se depuraron 6 ítems con mal ajuste y el instrumento pasó de 12 a 6 ítems.
- El análisis de clases latentes reveló dos estructuras unidimensionales (violencia hacia el entorno y hacia sí mismo), consistentes con un análisis factorial previo.

6 App web «Libro de la huerta»

Problema: registrar la producción diaria de una huerta agroecológica (siembras, cosechas, horas, destino y precio) y obtener totales sin planillas manuales. **Stack:** HTML/CSS/JavaScript sin dependencias, almacenamiento compartido entre usuarios, exportación a Excel. **Demo pública:** `https://claude.ai/artifact/NmsxD72VFG4dxhJzBXJsg5`

- Carga con validaciones por tipo de tarea (cosecha, siembra, mantenimiento) y especies configurables.
- Vistas **diario**, **por especie** y **patio**, con agregados por mes o período.
- Exportación a Excel de cada vista.
- Dos versiones: una productiva con datos compartidos entre los integrantes y una demo con datos de ejemplo que quedan solo en el navegador.
- Diseñada para celular y para usuarios sin experiencia técnica.



7 Investigación en teoría de números

Tipo: trabajo independiente, preprints sin revisión por pares (entre ellos, Zenodo DOI 10.5281/zenodo.17024858). **Stack:** Python, Coq, LaTeX. **Muestra:** `03_Muestras/Teoria_formal_Collatz.pdf`.

- Código Python de búsqueda y recorrido a gran escala sobre el árbol inverso de Collatz, con perfilado de memoria y del costo de iteración.
- Formalización en Coq de una teoría elemental, sin axiomas adicionales: razonamiento por invariantes que aplico también a la corrección de pipelines.
- Documentos largos en LaTeX con tablas y figuras generadas automáticamente.

8 Formación y certificaciones

- **Licenciatura en Análisis de Sistemas**, Universidad Nacional de Salta (2009). Título intermedio: **Computador Universitario** (2000).
- **Programa Experto en Ciencia de Datos**, Promidat, Costa Rica (2019). Diploma de Experto y diez módulos certificados, entre ellos bases de datos, manipulación de datos, análisis exploratorio, visualización, R, modelos predictivos, series de tiempo y web mining. Certificados en `04_Certificados/`.
- **SnowPro Core** (Snowflake), en curso.